КУРСОВАЯ РАБОТА

по дисциплине “Классическое машинное обучение”

на тему “Построение прогноза, позволяющего подобрать наиболее эффективное сочетание параметров для создания лекарственных препаратов”

Выполнил: Шилов Кирилл

Группа: М25-525

Оглавление

Аналитический отчёт: Прогнозирование эффективности химических соединений против вируса гриппа 3
1. Введение и постановка задачи 3
1.1. Контекст исследования 3
1.2. Описание целевых показателей 3
1.3. Цели работы 3
2. Разведочный анализ данных (EDA) 4
2.1. Характеристики датасета 4
2.2. Анализ и очистка данных 4
2.3. Анализ целевых переменных 4
2.4. Выводы по EDA 5
3. Регрессионный анализ 6
3.1. Методология 6
3.2. Регрессия IC50 6
3.3. Регрессия CC50 7
3.4. Регрессия SI 7
3.5. Общие выводы по регрессионным задачам 8
4. Классификационный анализ 9
4.1. Методология 9
4.2. Классификация IC50 > медианы 9
4.3. Классификация CC50 > медианы 10
4.4. Классификация SI > медианы 10
4.5. Классификация SI > 8 11
4.6. Сравнение порогов для SI 11
4.7. Роль калибровки вероятностей 12
5. Сравнительный анализ всех подходов 13
5.1. Сводная таблица результатов 13
5.2. Ключевые выводы 13
5.3. Практическая значимость результатов 14
6. Практические рекомендации 15
6.1. Интерпретация важности признаков 15
6.2. По улучшению моделей 15
6.3. По продолжению исследования 15
7. Заключение 16

Аналитический отчёт: Прогнозирование эффективности химических соединений против вируса гриппа

1. Введение и постановка задачи

1.1. Контекст исследования

Разработка эффективных противовирусных препаратов требует систематического подхода к отбору перспективных химических соединений. Традиционные методы синтеза и тестирования соединений являются ресурсоёмкими и времязатратными. Применение методов машинного обучения позволяет существенно ускорить процесс отбора кандидатов за счёт предсказания их эффективности на основе структуры и физико-химических свойств.

1.2. Описание целевых показателей

Эффективность соединений характеризуется тремя ключевыми показателями:

- **IC50 (Inhibitory Concentration 50)** - концентрация соединения, необходимая для ингибирования 50% вирусной активности. Чем ниже значение IC50, тем эффективнее соединение подавляет вирус.
- **CC50 (Cytotoxic Concentration 50)** - концентрация, вызывающая гибель 50% здоровых клеток. Высокие значения CC50 указывают на низкую цитотоксичность.
- **SI (Selectivity Index)** - индекс селективности, рассчитываемый как SI = CC50 / IC50. Высокие значения SI (обычно > 8-10) указывают на хороший терапевтический профиль: соединение эффективно против вируса при низкой токсичности для клеток.

1.3. Цели работы

Целью исследования является построение прогнозных моделей для:

1. Предсказания численных значений IC50, CC50 и SI (задачи регрессии)

2. Классификации соединений по пороговым значениям (задачи бинарной классификации)

3. Сравнительного анализа различных подходов машинного обучения

4. Составление практических рекомендаций для отбора перспективных соединений

2. Разведочный анализ данных (EDA)

2.1. Характеристики датасета

Исходный датасет содержал информацию о 1000 химических соединениях, описываемых 214 признаками.

Таблица 1. Этапы предобработки данных

Этап	До	После	Комментарий
Количество строк	1001	998	Удалено 3.6% строк с пропусками
Количество признаков	214	168	Удалены константные и мультиколлинеарные признаки
Дубликаты	0	0	Дубликатов не обнаружено

2.2. Анализ и очистка данных

Константные признаки: Обнаружено и удалено 18 признаков, не содержащих вариативности. Такие признаки не несут информации для моделирования.

Мультиколлинеарность: Найдено 154 пары признаков с коэффициентом корреляции > 0.9. Удалено 27 признаков для снижения мультиколлинеарности, что способствует:

- Повышению интерпретируемости моделей
- Снижению риска переобучения
- Ускорению обучения моделей

2.3. Анализ целевых переменных

Таблица 2. Описательная статистика целевых переменных

Показатель	IC50, mM	CC50, mM	SI
Среднее	221.12	586.67	72.65
Медиана	45.99	408.79	3.86
Std	400.51	642.02	685.50
Min	0.0035	0.70	0.01
Max	4128.53	4538.98	15620.60

Ключевые наблюдения:

1. **Экспоненциальное распределение:** Все три целевые переменные имеют сильно скошенное распределение с длинным хвостом вправо. Большинство соединений имеют низкие значения, но присутствуют выбросы.

2. **Выбросы:** Метод IQR (3*IQR) выявил:

   – 87 выбросов (8.7%) для IC50
   – 11 выбросов (1.1%) для CC50
   – 86 выбросов (8.6%) для SI

   Выбросы были оставлены в выборке, так как:

   – Их доля существенна (17.6% уникальных строк)
   – Они могут представлять перспективные соединения с аномально высокой эффективностью
   – Удаление может исказить распределение

2.4. Выводы по EDA

Датасет представляет собой сложную задачу для моделирования по следующим причинам:

- Значительное количество выбросов

- Отсутствие сильных линейных связей между признаками и целевыми переменными

3. Регрессионный анализ

3.1. Методология

Для каждой регрессионной задачи были обучены и сравнены следующие модели:

- Линейная регрессия (бейзлайн)

- Random Forest с GridSearchCV

- Gradient Boosting с GridSearchCV

- XGBoost с Optuna (50 trials)

- LightGBM с Optuna

Метрики качества: R^2, RMSE на тестовой выборке

3.2. Регрессия IC50

Таблица 3. Сравнение моделей для предсказания IC50

Модель	R^2 (train)	R^2 (test)	RMSE (test)
Linear Regression	0.4975	-24744.60*	82676.16
Random Forest	0.7716	**0.4439**	**391.92**
Gradient Boosting	0.7019	0.4388	393.73
XGBoost	0.7519	0.4392	393.59
LightGBM	0.6706	0.4206	400.06

Лучшая модель: Random Forest (max_depth=10, min_samples_split=5, n_estimators=300)

Интерпретация результатов:

1. **R^2 = 0.44** означает, что модель объясняет примерно 44% дисперсии IC50. Это умеренный результат для сложной биологической задачи.

2. **Разрыв между train и test R^2** (0.77 vs 0.44) указывает на зашумлённость данных.

3. **Random Forest превзошёл бустинговые модели**, возможно, благодаря большей устойчивости к выбросам и нелинейным зависимостям.

3.3. Регрессия CC50

Таблица 4. Сравнение моделей для предсказания CC50

Модель	R^2 (train)	R^2 (test)	RMSE (test)
Linear Regression	0.5274	-212.10*	29535.71
Random Forest	0.8330	0.4667	500.79
Gradient Boosting	0.7844	0.4632	502.39
XGBoost	0.8848	**0.4727**	**498.42**
LightGBM	0.8146	0.4628	501.69

Лучшая модель: XGBoost (n_estimators=200, max_depth=6, learning_rate=0.0136, subsample=0.603, colsample_bytree=0.914, min_child_weight=2)

Ключевые выводы:

1. **XGBoost показал наилучший результат** среди всех моделей, хотя отрыв от Random Forest минимален (0.47 vs 0.46).
2. **Возможно присутствует переобучение** (train R^2 = 0.88) указывает на необходимость дополнительной регуляризации.

3.4. Регрессия SI

Таблица 5. Сравнение моделей для предсказания SI

Модель	R^2 (train)	R^2 (test)	RMSE (test)
Linear Regression	0.3578	-1.13*	3298.33
Random Forest	0.2464	**0.0854**	**1359.25**
Gradient Boosting	0.2104	0.0426	1399.05
XGBoost	0.3153	0.0616	1383.30
LightGBM	0.2899	0.0662	1379.29

Лучшая модель: Random Forest (max_depth=None, min_samples_split=10, n_estimators=100)

Критическая оценка:

1. **R^2 = 0.085** - крайне низкий показатель. Модель практически не объясняет вариабельность SI.
2. **SI - самая сложная для предсказания величина.** Так как SI = CC50 / IC50, и ошибки в предсказании обеих компонент накапливаются.

3. **Практическая неприменимость:** Текущие модели не могут надёжно предсказывать численные значения SI.

3.5. Общие выводы по регрессионным задачам

Таблица 6. Сводка результатов регрессии

Целевая переменная	Лучшая модель	R^2 (test)	Оценка применимости
IC50	Random Forest	0.4439	Умеренная
CC50	XGBoost	0.4727	Умеренная
SI	Random Forest	0.0854	Неудовлетворительная

Ключевые выводы:

1. Регрессионные задачи показали низкую предсказательную способность ($R^2 < 0.5$).
2. XGBoost и Random Forest - наиболее стабильные алгоритмы для данного типа данных.
3. Прямое предсказание SI неэффективно. Рекомендуется предсказывать IC50 и CC50 отдельно, а затем вычислять SI, или использовать классификацию по порогу.
4. Для получения лучшего качества стоит собрать больше данных.

4. Классификационный анализ

4.1. Методология

Для каждой классификационной задачи были обучены:

- Логистическая регрессия (бейзлайн)
- Random Forest с GridSearchCV
- Gradient Boosting с GridSearchCV
- XGBoost с Optuna
- LightGBM с Optuna
- Калиброванные версии моделей (isotonic calibration)

Метрики качества: Accuracy, Precision, Recall, F1, ROC-AUC.

4.2. Классификация IC50 > медианы

Медианное значение: 45.99 mM

Таблица 7. Сравнение моделей для классификации IC50 > медианы

Модель	ROC-AUC	F1	Accuracy
Logistic Regression	0.7871	0.7061	0.7050
Random Forest	**0.7974**	**0.7586**	**0.7550**
Gradient Boosting	0.7895	0.7389	0.7350
XGBoost	0.7880	0.7436	0.7400
LightGBM	0.7911	0.7368	0.7300

Лучшая модель: Random Forest (max_depth=10, min_samples_split=5, n_estimators=200)

Интерпретация:

1. **ROC-AUC = 0.80** - хороший результат для бинарной классификации. Модель с вероятностью 80% правильно ранжирует случайное соединение.
2. **Значительное улучшение по сравнению с регрессией:** Классификация работает лучше, чем предсказание точного значения IC50.
3. **Сбалансированные метрики:** Accuracy = 75.5%, F1 = 75.9% indicate сбалансированную работу с обоими классами.

4.3. Классификация CC50 > медианы

Медианное значение: 408.79 mM

Таблица 8. Сравнение моделей для классификации CC50 > медианы

Модель	ROC-AUC	F1	Accuracy
Logistic Regression	0.8122	0.7383	0.7200
Random Forest	**0.8608**	**0.7826**	**0.7750**
Gradient Boosting	0.8423	0.7512	0.7450
XGBoost	0.8539	0.7656	0.7550
LightGBM	0.8293	0.7451	0.7400

Лучшая модель: Random Forest (max_depth=10, min_samples_split=10, n_estimators=300)

Ключевые наблюдения:

1. **ROC-AUC = 0.86 – лучший результат среди всех задач.** Классификация по CC50 работает наиболее эффективно.
2. **Высокая предсказуемость цитотоксичности:** Структурные особенности молекул более детерминированно влияют на CC50, чем на IC50.
3. **Практическая значимость:** Модель может эффективно отсекать высокотоксичные соединения на ранних этапах скрининга.

4.4. Классификация SI > медианы

Медианное значение: 3.86

Таблица 9. Сравнение моделей для классификации SI > медианы

Модель	ROC-AUC	F1	Accuracy
Logistic Regression	0.6623	0.5970	0.6200
Random Forest	**0.6948**	**0.6105**	**0.6300**
Gradient Boosting	0.6846	0.6026	0.6250
XGBoost	0.6880	0.6076	0.6300
LightGBM	0.6844	0.6046	0.6150

Лучшая модель: Random Forest (max_depth=10, min_samples_split=10, n_estimators=300)

Анализ:

1. **ROC-AUC = 0.69 - умеренный результат.** Модель различает классы, но значительно хуже, чем для IC50 и CC50.

2. **Сложность предсказания SI:** Промежуточный характер показателя (отношение двух величин) снижает предсказуемость.

4.5. Классификация SI > 8

Пороговое значение: SI = 8 (клинически значимый уровень селективности)

Таблица 10. Сравнение моделей для классификации SI > 8

Модель	ROC-AUC	F1	Accuracy
Logistic Regression	0.6928	0.5273	0.7150
Random Forest	**0.7288**	**0.5620**	**0.7350**
Gradient Boosting	0.7190	0.5524	0.7300
XGBoost	0.7250	0.5576	0.7300
LightGBM	0.7188	0.5492	0.7250

Лучшая модель: Random Forest (max_depth=10, min_samples_split=10, n_estimators=300)

Баланс классов: 64% (SI ≤ 8) vs 36% (SI > 8)

Выводы:

1. **ROC-AUC = 0.73 - удовлетворительный результат.** Предсказание по фиксированному порогу работает лучше, чем по медиане.

2. **Accuracy = 73.5%** достигается в основном за счёт правильного предсказания более крупного класса (низкая селективность).

3. **Низкий F1 = 0.56** указывает на сложности с выявлением высокоселективных соединений.

4.6. Сравнение порогов для SI

Таблица 11. Сравнение классификации SI по разным порогам

Порог	ROC-AUC	F1	Precision	Recall
Медиана (3.86)	0.6948	0.6105	0.6333	0.6300
Фиксированный (8)	0.7288	0.5620	0.6400	0.5000

Интерпретация:

1. **Фиксированный порог SI > 8 даёт более высокий ROC-AUC**, но более низкий F1.
2. **Задача с фиксированным порогом более дисбалансирована**, что снижает F1 для миноритарного класса.

4.7. Роль калибровки вероятностей

Калибровка вероятностей (isotonic calibration) была применена к Logistic Regression и Random Forest. Результаты показали:

- **Logistic Regression:** ROC-AUC снизился с 0.8122 до 0.8089
- **Random Forest:** ROC-AUC практически не изменился (0.8608 → 0.8546)

Вывод: Калибровка не принесла значительных улучшений для данной задачи. Модели уже выдают хорошо откалиброванные вероятности.

5. Сравнительный анализ всех подходов

5.1. Сводная таблица результатов

Таблица 12. Итоговые результаты всех моделей

Задача	Тип	Лучшая модель	Главная метрика	Значение
IC50 предсказание	Регрессия	Random Forest	R^2	0.4439
CC50 предсказание	Регрессия	XGBoost	R^2	0.4727
SI предсказание	Регрессия	Random Forest	R^2	0.0854
IC50 > медианы	Классификация	Random Forest	ROC-AUC	0.7974
CC50 > медиана	Классификация	Random Forest	ROC-AUC	**0.8608**
SI > медиана	Классификация	Random Forest	ROC-AUC	0.6948
SI > 8	Классификация	Random Forest	ROC-AUC	0.7288

5.2. Ключевые выводы

1. Классификация работает лучше регрессии

ROC-AUC для классификационных задач (0.70-0.86) значительно выше, чем R^2 для регрессионных (0.08-0.47). Это указывает на то, что:

- Категорическое разделение соединений на «эффективные/неэффективные» более устойчиво к шуму
- Точные численные предсказания затруднены из-за высокой вариабельности биологических данных

2. CC50 - наиболее предсказуемая характеристика

Лучшие результаты достигнуты для классификации CC50 (ROC-AUC = 0.86). Это может объясняться тем, что:

- Методы измерения CC50 более стандартизированы

3. SI - сложная цель для прямого моделирования

Низкий R^2 = 0.085 для регрессии и средний ROC-AUC = 0.69-0.73 для классификации подтверждают сложность предсказания селективности.

4. Random Forest – наиболее подходящая модель для задач

Random Forest показал лучшие результаты в 6 из 7 задач, что подтверждает его устойчивость к:

- Выбросам в данных

- Нелинейным зависимостям

- Мультиколлинеарности признаков

5.3. Практическая значимость результатов

Таблица 13. Рекомендации по практическому применению

Задача	Рекомендуемая модель	Применимость
Первичный скрининг на токсичность	Random Forest CC50	Высокая
Отбор по эффективности	Random Forest IC50	Умеренная
Оценка селективности	Классификация SI > 8	Ограниченная

6. Практические рекомендации

6.1. Интерпретация важности признаков

Анализ feature importance для лучших моделей выявил наиболее значимые молекулярные дескрипторы. Эти признаки могут быть использованы для: - Направленного химического модифицирования соединений - Понимания структурных факторов, влияющих на активность

6.2. По улучшению моделей

1. Предобработка данных

- **Логарифмирование целевых переменных** для снижения влияния выбросов и приближения распределения к нормальному
- **Генерация новых признаков:**
  - Полиномиальные признаки
  - Взаимодействия между топ-дескрипторами
  - Агрегированные характеристики (отношения признаков)
- **Борьба с дисбалансом классов** для задачи SI > 8

2. Методы ансамблирования

- **Стекинг** лучших моделей (XGBoost + LightGBM + Random Forest)
- **Blending** - усреднение предсказаний
- **Бэггинг** с различными подвыборками признаков

3. Расширенный подбор гиперпараметров

- Увеличить количество параметров в Optuna

6.3. По продолжению исследования

1. Сбор дополнительных данных

- Увеличение размера выборки (текущие 1000 соединений недостаточно для сложных моделей)
- Включение разнообразных химических классов
- Стандартизация методов измерения IC50/CC50

2. Валидация на внешних датасетах

- Проверка обобщающей способности на данных из других источников

3. Интерпретируемые модели

- Использование SHAP значений для интерпретации предсказаний

7. Заключение

В ходе исследования была решена задача построения прогнозных моделей для оценки эффективности химических соединений против вируса гриппа. Проведённый анализ показал, что:

1. Классификационные задачи решаются существенно лучше регрессионных.
2. Наилучшие результаты достигнуты для предсказания цитотоксичности (CC50) - ROC-AUC = 0.86, что позволяет эффективно использовать модель для первичного скрининга.
3. Предсказание селективности (SI) представляет наибольшую сложность из-за производного характера показателя.
4. Random Forest продемонстрировал наилучшие результаты в большинстве задач, подтвердив свою универсальность для табличных данных с выбросами и мультиколлинеарностью.

Построенные модели могут быть использованы для:

- Предварительного скрининга химических соединений перед синтезом
- Направленного модифицирования структуры молекул
- Приоритизации кандидатов для экспериментального тестирования

Дальнейшее улучшение качества моделей возможно за счёт расширения датасета, генерации дополнительных признаков и использования более сложных ансамблевых методов.